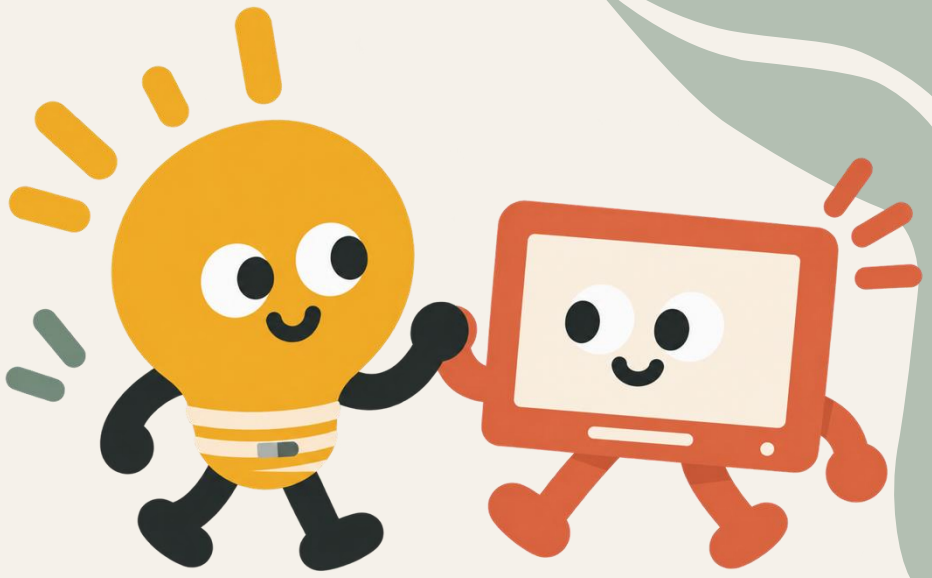
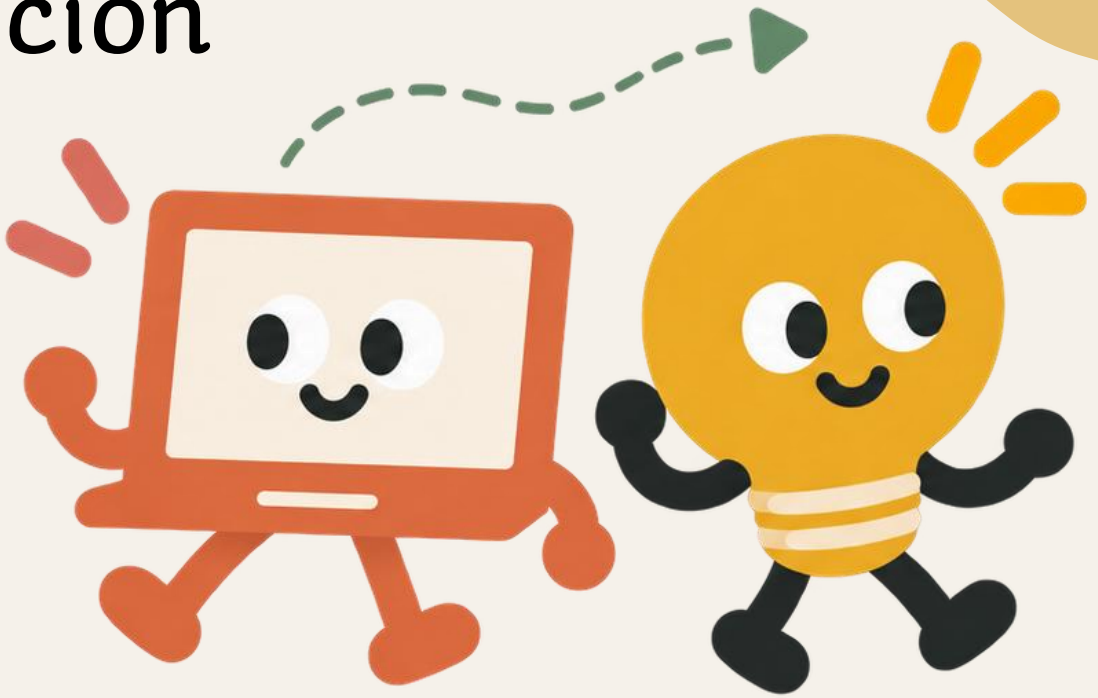
Módulo 2

Taller teórico-práctico
Del dataset a U-Net: segmentación de imágenes con Deep Learning

→ Ingeniería del dataset



Inventario y configuración del dataset



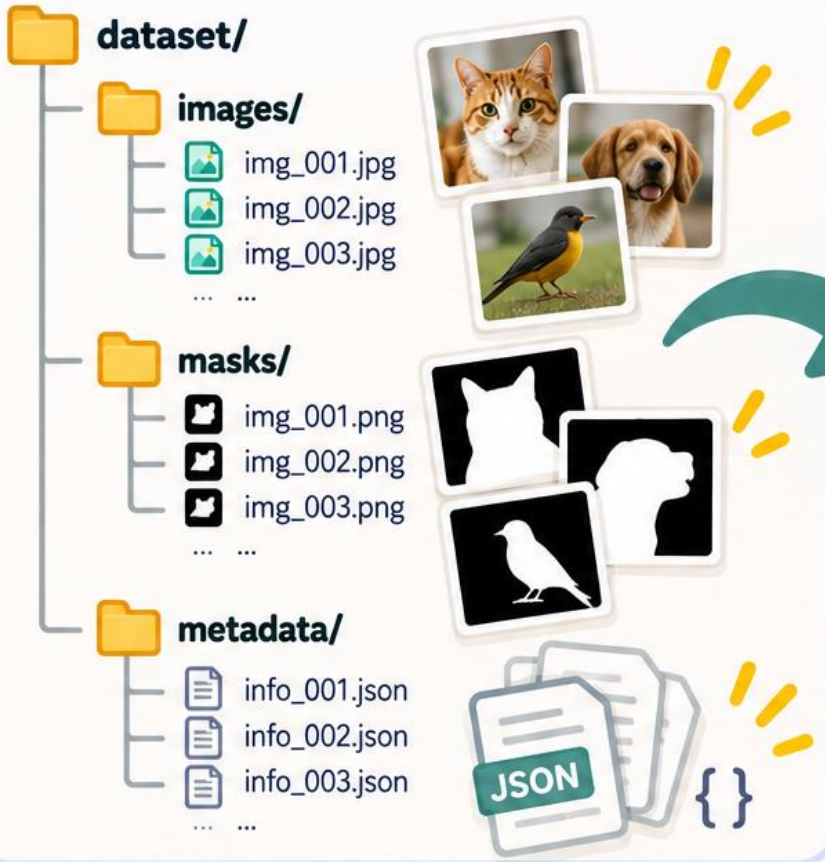

Mi dataset tiene miles de imágenes.
¿Realmente quiero recorrer todas las carpetas manualmente cada vez que necesite saber qué archivos existen y dónde se encuentran?

Manifest:

inventario estructurado que registra los elementos de un dataset y la información necesaria para identificarlos y localizarlos.



Archivos distribuidos en directorios



Manifest (inventario estructurado)

image_id	image_path	mask_path	width	height	format
 img_001	images/ img_001.jpg	masks/ img_001.png	640	480	jpg/png
 img_002	images/ img_002.jpg	masks/ img_002.png	640	480	jpg/png
 img_003	images/ img_003.jpg	masks/ img_003.png	640	480	jpg/png
...	...	...	...	...	...

Archivo de configuración del dataset

El archivo `config/dataset.json` te va a servir para centralizar la información que necesita tu proyecto para encontrar, interpretar y utilizar el dataset.



No es indispensable para que el proyecto funcione. Podrías escribir todas las rutas directamente en tus notebooks. Su utilidad aparece cuando empiezas a tener varios notebooks, scripts, experimentos o datasets.

Sin archivo de configuración

Las rutas están escritas directamente en cada notebook.

Ruta original del dataset

`/data/animales_v1/`

Nueva ubicación del dataset

`/data/animales_v2/`

¡Hay que cambiar esta ruta en todos los notebooks!

01_exploracion.ipynb

```
data_dir =
"/data/animales_v1/"
...
```

02_preprocesamiento.ipynb

```
data_dir =
"/data/animales_v1/"
...
```

03_entrenamiento.ipynb

```
data_dir =
"/data/animales_v1/"
...
```



Con archivo de configuración

Solo actualizas la ruta una vez en `config/dataset.json`.

config/dataset.json

```
{
  "name": "animales",
  "root_dir": "/data/animales_v2/",
  "images_dir": "images/",
  "masks_dir": "masks/",
  ...
}
```

Cambiamos la ruta del dataset una sola vez.

Todos los notebooks usan la misma configuración.

01_exploracion.ipynb

```
from utils.config import
get_paths

paths = get_paths()
data_dir = paths["root_dir"]
...
```

02_preprocesamiento.ipynb

```
from utils.config import
get_paths

paths = get_paths()
data_dir = paths["root_dir"]
...
```

03_entrenamiento.ipynb

```
from utils.config import
get_paths

paths = get_paths()
data_dir = paths["root_dir"]
...
```



¡Mucho más fácil de mantener!