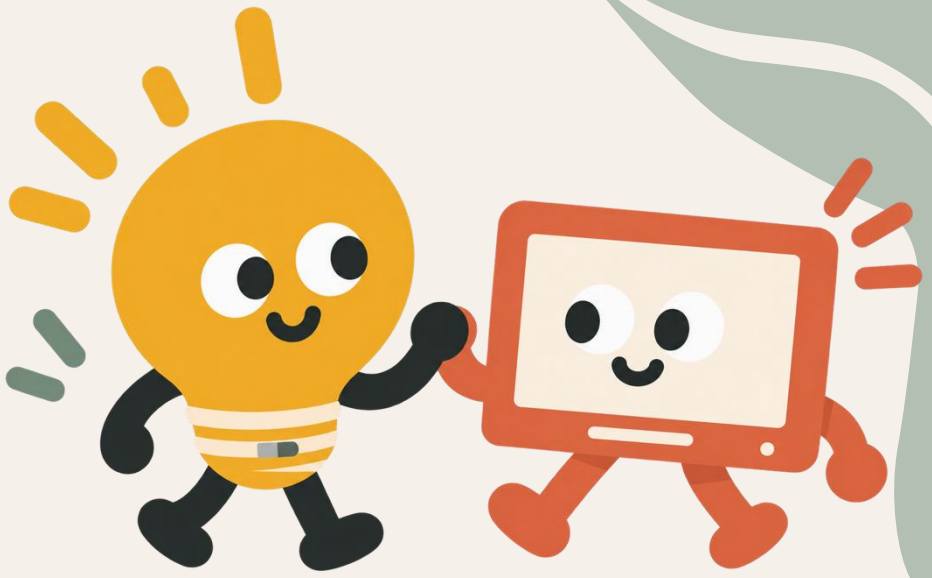
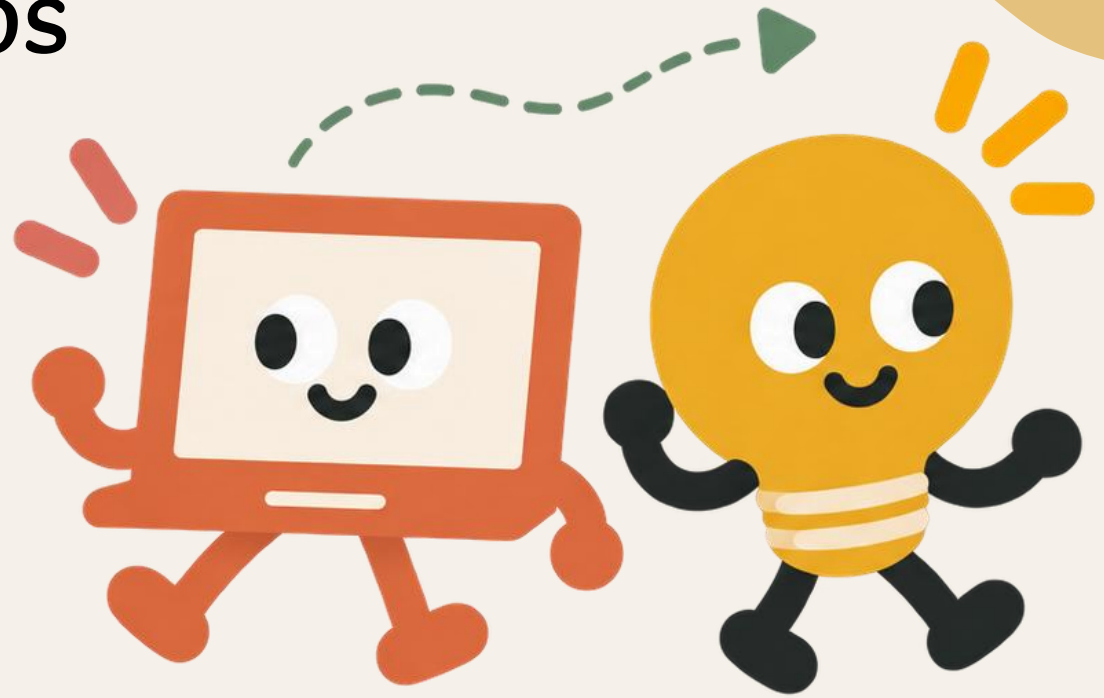
Módulo 4

Taller teórico-práctico
Del dataset a U-Net: segmentación de imágenes con Deep Learning

→ Diseño experimental y pipeline de datos

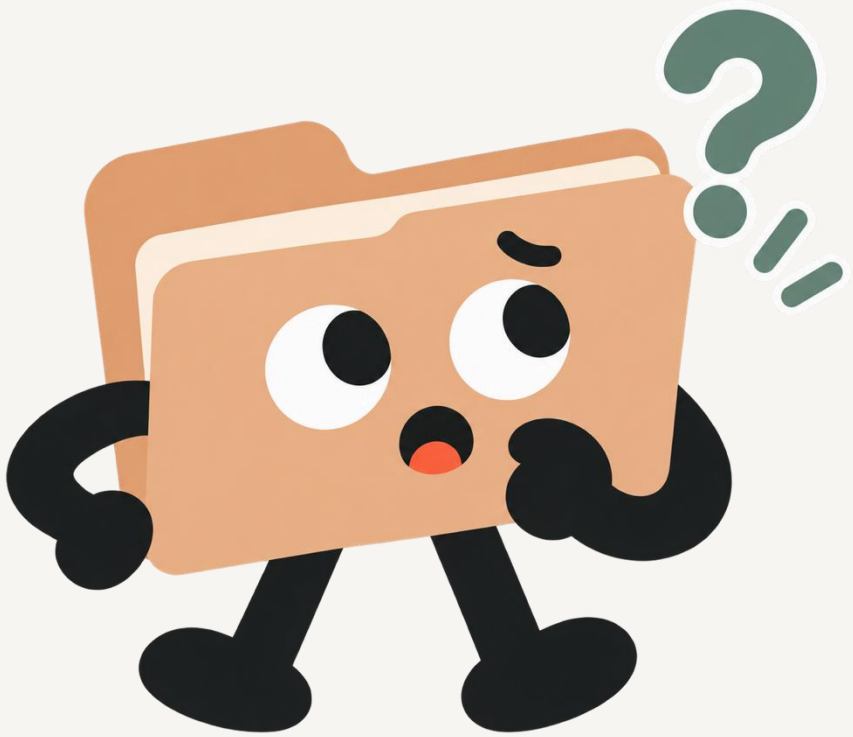


Diseño de los conjuntos experimentales



Tenemos imágenes, máscaras, rutas, dimensiones y sabemos cómo transformarlas.

¿Podemos entrenar con todas las imágenes y después utilizar esas mismas imágenes para evaluar nuestro modelo?



Conjuntos de datos: propósito

Dividimos el **dataset** en tres conjuntos para entrenar, ajustar y evaluar de forma justa el modelo.

Cada conjunto tiene un propósito diferente.



1 Train

Aprender parámetros

Se utiliza para entrenar el modelo y aprender sus parámetros (pesos) mediante backpropagation.



Ejemplos de entrenamiento (mayoría de los datos)

Entrenamiento

Ajusta los pesos del modelo mediante backpropagation.

2 Validation

Seleccionar y ajustar

Se utiliza para comparar configuraciones, ajustar hiperparámetros y seleccionar el mejor modelo (checkpoint).



Ejemplos de validación (una fracción de los datos)

Evaluación durante el desarrollo

Se calcula el rendimiento, pero no se actualizan directamente los pesos del modelo.

3 Test

Evaluación final

Se utiliza una sola vez, al final del proceso, para estimar el rendimiento del modelo sobre datos no vistos.



Ejemplos de prueba (datos reservados)

Evaluación final

Proporciona una estimación imparcial del rendimiento. No debe usarse para ajustar el modelo.

Conjunto	Función	¿Se utiliza para ajustar el modelo?
Train	Aprender los parámetros mediante entrenamiento.	**Sí**
Validation	Comparar configuraciones, ajustar hiperparámetros y seleccionar checkpoints.	**Sí, indirectamente**
Test	Estimar el rendimiento final sobre datos reservados.	**No**

Punto clave sobre validation

- El conjunto de validación no actualiza directamente los pesos del modelo (no se usa backpropagation).
- Sin embargo, **sí influye en** las decisiones de diseño, como la selección de hiperparámetros, la comparación de arquitecturas y la elección del mejor checkpoint. Por eso se considera que **sí se utiliza para ajustar el modelo, pero de forma indirecta.**

Importante

El conjunto de test debe permanecer reservado y no debe utilizarse durante el entrenamiento ni para ajustar hiperparámetros.

Se utiliza únicamente al final, cuando ya se han tomado todas las decisiones de diseño.

Proporciones comunes de los conjuntos

No existe una distribución universalmente óptima. Las proporciones dependen del tamaño del dataset, la variabilidad de las muestras, el número de clases y la precisión con la que necesitamos estimar el rendimiento del modelo.

Estas son algunas configuraciones frecuentes en la práctica. Son convenciones, no estándares obligatorios.



Train	Validation	Test	Uso habitual
60 %	20 %	20 %	Datasets relativamente pequeños; reserva más ejemplos para evaluación.
70 %	15 %	15 %	Distribución equilibrada, sencilla para enseñar.
80 %	10 %	10 %	Frecuente cuando se quiere aprovechar más información para entrenamiento.
80 %	20 %	—	Cuando existe un conjunto de prueba externo o se utiliza otro procedimiento de evaluación.
90 %	5 %	5 %	Datasets grandes, donde incluso el 5 % representa muchos ejemplos.

1 Train

Aprender los parámetros



La mayor parte de los datos se utiliza para entrenar el modelo.

2 Validation

Seleccionar y ajustar



Se usa para comparar configuraciones, ajustar hiperparámetros y seleccionar el mejor modelo (checkpoint).

3 Test

Evaluación final



Se mantiene reservado hasta finalizar todas las decisiones de diseño y ajuste del modelo.

Puntos clave

- Estas proporciones son **convenciones, no estándares** obligatorios.
- No existe evidencia de que una proporción fija sea óptima para todos los problemas.
- La elección depende del tamaño del dataset, la variabilidad de las muestras, el número de clases y la precisión con la que necesitamos estimar el rendimiento del modelo.

Estrategias estandarizadas de partición

Además de las proporciones, existen diferentes formas de seleccionar las muestras para formar los conjuntos de entrenamiento, validación y prueba.

La estrategia de partición debe elegirse de acuerdo con las características del dataset y del problema.



Estrategia	¿Cómo funciona?	¿Cuándo utilizarla?
Holdout aleatorio	Divide el dataset una sola vez, aleatoriamente.	Experimentos iniciales y datasets suficientemente grandes.
Holdout estratificado	Divide aleatoriamente, procurando conservar las proporciones de categorías.	Clasificación con clases desbalanceadas.
Partición por grupos	Mantiene juntas las muestras relacionadas.	Varias imágenes del mismo paciente, animal o escena.
K-Fold Cross-Validation	Divide en K partes y realiza K entrenamientos, rotando la parte de validación.	Cuando interesa evaluar la variabilidad del rendimiento.
Stratified K-Fold	K-Fold conservando aproximadamente las proporciones de clases.	Clasificación con clases desbalanceadas.
Group K-Fold	K-Fold evitando compartir grupos entre entrenamiento y validación.	Imágenes correlacionadas entre sí.
Stratified Group K-Fold	Combina estratificación y separación por grupos.	Datos agrupados con clases desbalanceadas.

¿Qué es data leakage?

Data leakage: incorporación de información que no debería estar disponible durante el entrenamiento o la selección del modelo, provocando una evaluación potencialmente optimista.

Si información del conjunto de evaluación (sea la misma imagen, una versión muy similar o datos relacionados) aparece en el entrenamiento, el modelo puede "memorizar" en lugar de aprender a generalizar, y el rendimiento medido puede ser engañosamente alto.



A Misma imagen en entrenamiento y evaluación

La misma imagen (y su máscara) se usa tanto para entrenar como para evaluar.



El modelo puede memorizar la imagen y obtener un rendimiento artificialmente alto.

B Imágenes casi idénticas

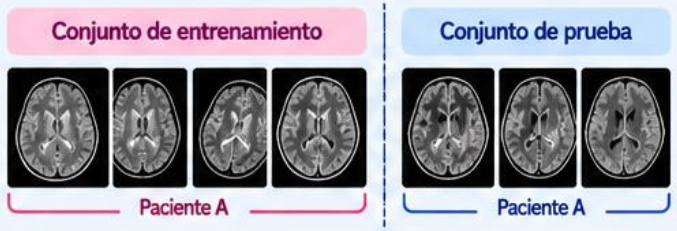
Se entrena con una imagen y se evalúa con una copia muy similar (por ejemplo, una versión con ligeros cambios de color, recorte o compresión).



El modelo ve información casi idéntica, lo que puede inflar el rendimiento de evaluación.

C Imágenes del mismo paciente (o entidad relacionada)

Se entrena con imágenes de un paciente y se evalúa con otras imágenes del mismo paciente.



El modelo puede aprender características específicas de ese paciente y no necesariamente generalizar a pacientes nuevos.

¿Por qué es un problema?

El rendimiento medido puede ser muy alto, pero no refleja la capacidad real del modelo para generalizar a datos nuevos.



Esto puede llevar a:

- Sobreestimar el rendimiento del modelo.
- Tomar decisiones incorrectas sobre su desempeño.
- Modelos que fallan cuando se aplican a datos realmente nuevos.

Relación con data augmentation

El data augmentation no debe realizarse antes de dividir el dataset, si eso permite que variantes de una misma imagen original terminen en conjuntos diferentes.

